Projeto Final - Fundamentos de Machine Learning

Em grupos de 3 ou 4 pessoas, vocês vão desenvolver um projeto de Machine Learning do problema à avaliação e apresentá-lo em Nov 12, 2026. Mais importante do que a complexidade do modelo é aplicar corretamente os fundamentos vistos na disciplina.

Tarefa

Cada grupo escolhe um dataset de sua preferência (Kaggle, UCI Machine Learning Repository, IBGE, dados sintéticos gerados com IA, entre outros) e desenvolve um projeto que coloque em prática o que vimos em sala: pré-processamento, aprendizado supervisionado e não supervisionado, regressão, classificação e clusterização, e boas práticas (overfitting, regularização, PCA, vazamento de informações, classes desbalanceadas).

O projeto deve passar por seis etapas:

1. **Descrição do problema:** o que vocês querem prever, classificar ou agrupar, e por que isso importa. Que decisão o modelo apoiaria?
2. **Pré-processamento e análise exploratória:** tratamento de valores ausentes, normalização ou transformação, codificação de variáveis categóricas e uma EDA que justifique essas escolhas.
3. **Definição da tarefa:** supervisionada ou não supervisionada; se supervisionada, regressão ou classificação.
4. **Construção do modelo:** algoritmos adequados ao problema, sempre comparados com uma **referência simples** (por exemplo, prever a média ou a classe mais comum).
5. **Avaliação:** métricas apropriadas ao problema, lidas na unidade do negócio (“erramos em média 2,5 anos”, “encontramos 70% dos clientes que cancelam”).
6. **Boas práticas, conforme a necessidade:** evitar overfitting, validação adequada, regularização, tratamento de classes desbalanceadas e cuidado com vazamento de informações.

O tema e o dataset são livres, mas cada grupo deve usar um dataset diferente. Evitem os datasets já usados em aula.

Entrega e apresentação

Tudo é entregue até o início da aula de 12/11, quando os grupos apresentam. Cada grupo tem até **20 minutos**: 15 de apresentação e até 5 de perguntas.

O que entregar

- **Notebook** (Jupyter ou Colab, com link de acesso) ou **PDF** com código e explicações. O notebook precisa rodar do início ao fim sem erros.
- **Slides** da apresentação.
- **Link ou arquivo do dataset**, e os nomes de todos os integrantes.

Roteiro sugerido para os 15 minutos

Parte	Tempo
Problema, dataset e por que importa	3 min
Preparação dos dados e principais achados da EDA	3 min
Modelos testados e comparação com a referência	5 min
Boas práticas aplicadas, limitações e conclusão	4 min

Todos os integrantes devem apresentar alguma parte e estar prontos para responder perguntas sobre qualquer etapa do projeto.

Critérios de avaliação

A nota vai de 0 a 10: 7 pontos vêm do notebook e 3 da apresentação. A nota é do grupo.

Critério	Pontos	Nota máxima quando...	Perde pontos quando...
1. Problema e dados	10	O alvo, a tarefa e a decisão que o modelo apoia estão claros; o dataset é descrito (fonte, linhas, colunas principais).	O problema é vago ou o dataset não é explicado.
2. Pré-processamento e EDA	15	Nulos, codificação e escala são tratados com justificativa; a EDA mostra achados que guiam as escolhas do modelo.	Nulos são removidos ou preenchidos sem explicação; a EDA só lista gráficos sem conclusões.
3. Modelagem	15	Os algoritmos combinam com a tarefa; há uma referência simples e pelo menos dois modelos comparados.	Um único modelo, sem referência, ou um algoritmo que não serve ao tipo de alvo.
4. Avaliação	15	As métricas são adequadas (por exemplo, recall ou F1 com classes raras), calculadas no teste e interpretadas na unidade do problema.	Só acurácia com classes desbalanceadas, métricas no treino ou números sem interpretação.
5. Boas práticas	15	A divisão treino/teste vem antes de qualquer ajuste; o grupo compara treino e teste, verifica vazamento e usa regularização, validação ou balanceamento quando o problema pede.	Pré-processamento ajustado na base inteira, features que contêm a resposta ou overfitting ignorado.
6. Comunicação	15	A apresentação conta uma história (problema, solução, resultado, limitações), cabe em 15 minutos e é compreensível para quem não é da área.	Slides cheios de código, tempo estourado ou nenhuma conclusão.
7. Domínio e perguntas	15	Todos apresentam e respondem com segurança sobre qualquer etapa; o grupo reconhece os limites do próprio modelo.	Uma pessoa concentra a apresentação ou o grupo não sabe explicar o que fez.

Lembrem: um modelo simples, bem avaliado e honesto sobre seus limites vale mais do que um modelo complexo aplicado sem cuidado.

Checklist antes de entregar

- ☐ O notebook roda do início ao fim (“Executar tudo”) sem erros.
- ☐ O problema, o alvo e a decisão que o modelo apoia estão escritos no início.
- ☐ Treino e teste foram separados antes de preencher nulos, escalar ou codificar.
- ☐ Cada feature estaria disponível no momento da previsão.
- ☐ Os modelos foram comparados com uma referência simples.
- ☐ As métricas foram escolhidas pelo tipo de problema e interpretadas em palavras.
- ☐ As limitações do modelo e dos dados aparecem nas conclusões.
- ☐ A apresentação foi ensaiada e cabe em 15 minutos, com todos os integrantes falando.
- ☐ Notebook (ou PDF), slides, link do dataset e nomes dos integrantes foram enviados.